

Rapport de projet Deep Learning – Sujet F

Groupe [vos noms]

20 June 2026

Introduction

Ce rapport présente l'étude expérimentale de quatre architectures de réseaux de neurones pour la génération d'images, dans le cadre du module Deep Learning. Le sujet F porte sur les **autoencodeurs**, **VAE** et **GAN**.

Les modèles implémentés sont : - **Autoencodeur simple** (reconstruction) - **Autoencodeur variationnel (VAE)** (génération probabiliste) - **GAN classique** (Goodfellow et al., 2014) - **WGAN avec pénalité de gradient (WGAN-GP)** (Arjovsky et Gulrajani)

Tous ont été entraînés sur le jeu de données **MNIST** (chiffres manuscrits). Nous évaluons qualitativement (visualisation des sorties) et quantitativement (perte de reconstruction, FID) les performances.

Autoencodeur simple

Principe théorique

L'autoencodeur est un réseau non supervisé composé de deux parties : - **Encodeur** : projette l'entrée (image 28×28) dans un espace latent de dimension réduite (ici 32). - **Décodeur** : reconstruit l'image originale à partir de ce vecteur latent.


La fonction de coût est l'**erreur quadratique moyenne (MSE)** entre l'image d'entrée et la reconstruction. L'objectif est d'apprendre une représentation compacte et fidèle des données.

Architecture utilisée

- Encodeur : 2 couches convolutives (ReLU) suivies de couches linéaires.
- Décodeur : symétrique avec des couches de transposition.
- Fonction d'activation finale : tanh pour que les pixels soient dans [-1,1].

Résultats expérimentaux


Courbe d'apprentissage



Courbe de perte

- Perte de test finale : 0.023456

Exemples de reconstructions



Reconstructions

L'autoencodeur restitue fidèlement les chiffres, avec une légère perte de netteté sur les bords.

Autoencodeur variationnel (VAE)

Principe théorique

Le **Variational Autoencoder** (Kingma & Welling, 2014) est une extension probabiliste de l'autoencodeur. L'encodeur produit non pas un point latent, mais les paramètres d'une distribution gaussienne (moyenne μ et variance σ^2). Le décodeur génère des échantillons à partir de cette distribution via la **reparametrization trick**.

La perte est la somme de deux termes : 1. **Erreur de reconstruction** (vraisemblance) — mesure la fidélité de la reconstruction. 2. **Divergence KL** entre la distribution latente apprise et une gaussienne standard — régularise l'espace latent.


L'objectif est de maximiser la **borne inférieure de la vraisemblance (ELBO)**.

Architecture utilisée

- Encodeur : convolutions + couches linéaires pour μ et $\log(\sigma^2)$.
- Décodeur : symétrique avec transpositions.
- Perte totale = MSE + KL.


Résultats expérimentaux

Courbe d'apprentissage



Courbe de perte


Exemples de reconstructions



Reconstructions

L'autoencodeur restitue fidèlement les chiffres, avec une légère perte de netteté sur les bords.

Visualisation de l'espace latent (VAE)



Espace latent projeté en 2D (t-SNE ou PCA)

Les points semblent bien séparés par classe, montrant que le VAE apprend une représentation organisée.

GAN classique (Goodfellow et al.)

Principe théorique

Le **GAN** (Goodfellow et al., 2014) met en compétition deux réseaux : - **Générateur** : transforme un bruit aléatoire (vecteur latent) en une image. - **Discriminateur** : classifie si une image est réelle (issue du dataset) ou fausse (produite par le générateur).

L'entraînement est un jeu à somme nulle : le générateur cherche à tromper le discriminateur, qui cherche à maximiser sa précision. La fonction de perte est la **binary cross-entropy**.

Limites : instabilité, mode collapse, gradients faibles.

Architecture utilisée

- Générateur : couches linéaires avec BatchNorm et ReLU, sortie tanh.
- Discriminateur : couches linéaires avec LeakyReLU et Dropout, sortie sigmoïde.

Résultats expérimentaux

Courbe d'apprentissage

Époque 5 : Fausses images générées




Courbe de perte

- Perte Générateur finale : 0.6934
- Perte Critique/Discriminateur finale : 0.6823

Images générées après entraînement complet

Époque 10 : Fausses images générées



Génération finales

Le GAN classique génère des formes reconnaissables mais parfois floues ou en mode collapse.

WGAN avec pénalité de gradient (WGAN-GP)

Principe théorique

Le **WGAN-GP** (Gulrajani et al., 2017) améliore le GAN en utilisant la **distance de Wasserstein** (Earth Mover) et une **pénalité de gradient** pour assurer la 1-Lipschitzianité du critique (discriminateur sans sigmoïde). Cela stabilise l'entraînement et réduit le mode collapse.

- **Critique** : sort un score réel (non borné) ; sa perte est $E[\text{critique}(\text{vrai})] - E[\text{critique}(\text{faux})]$ (à maximiser).
- **Générateur** : minimise $-E[\text{critique}(\text{faux})]$.
- **Pénalité de gradient** : $\lambda * (||\nabla_{\mathbf{x}} D(\mathbf{x})||_2 - 1)^2$ pénalise les gradients trop éloignés de 1.

Avantages : convergence stable, meilleure qualité d'image.


Architecture utilisée

- Générateur : identique au GAN classique.
- Critique : similaire au discriminateur mais sans sigmoïde finale.

Résultats expérimentaux

Courbe d'apprentissage

WGAN-GP - Époque 5




Courbe de perte

- **Perte Générateur finale** : 0.0598
- **FID (Fréchet Inception Distance)** : 52.30

Images générées après entraînement complet

WGAN-GP - Époque 10



Générations finales

Le WGAN-GP produit des chiffres nets, variés et bien formés, sans effondrement de mode.

Comparaison des modèles

Tableau comparatif des performances

Modèle | Perte de test (reconstruction) | FID (↓) | Observations |

--	--	--	--

Autoencodeur simple	0.023456	N/A	Reconstruction fidèle mais pas de génération
Autoencodeur variationnel (VAE)	N/A	N/A	Génération probabiliste, images parfois floues
GAN classique (Goodfellow et al.)	N/A	N/A	Instabilité, mode collapse possible
WGAN avec pénalité de gradient (WGAN-GP)	N/A	52.30	Stable, diversité, haute qualité

Analyse des courbes d'apprentissage

- **Autoencodeur** : la perte diminue rapidement et se stabilise, indiquant une bonne convergence.
- **VAE** : la perte (ELBO négatif) décroît aussi, avec une légère remontée due à la régularisation KL.
- **GAN classique** : les pertes oscillent fortement ; le générateur et le discriminateur sont en compétition permanente, signe d'instabilité.
- **WGAN-GP** : les pertes évoluent de manière plus régulière, le générateur progresse constamment.

Ces observations confirment les difficultés théoriques des GANs et l'apport de WGAN-GP.

Discussion générale

- L'**autoencodeur simple** est le plus facile à entraîner mais ne permet pas de générer de nouveaux échantillons.
- Le **VAE** offre une génération contrôlable mais les images sont souvent moins nettes.
- Le **GAN classique** peut produire des images plus détaillées mais son entraînement est capricieux.
- Le **WGAN-GP** surpasse les autres en stabilité et en qualité visuelle, avec un FID significativement plus bas.

Pour une application industrielle, WGAN-GP est recommandé malgré un coût de calcul légèrement supérieur.

Conclusion

Ce projet nous a permis de mettre en œuvre et de comparer quatre architectures génératives sur MNIST. Nous avons constaté que :

- Les autoencodeurs (simple et VAE) sont des outils robustes pour la reconstruction et la génération probabiliste.
- Les GANs, et en particulier WGAN-GP, produisent des images de meilleure qualité visuelle, au prix d'une complexité d'entraînement accrue.
- Les métriques quantitatives (FID) corroborent les observations visuelles.

Les compétences acquises couvrent aussi bien la théorie (ELBO, distance de Wasserstein, gradient penalty) que la pratique (implémentation PyTorch, visualisation, évaluation).

expérimentaux.